IIC2523
Sistemas Distribuidos

Hernán F. Valdivieso López
(2026 - 1 / Clase 08)

Elección de Líder

Temas de la clase

1. Algoritmos de elección de líder.
2. Algoritmo *Bully*.
3. Algoritmo *Raft*: consenso de información a través de un líder.
4. *Ring-based Election*.

Algoritmos de elección de líder

Elección de líder

- Consiste en elegir un nodo/proceso único para desempeñar un **rol particular** en un sistema distribuido:
  - Coordinador.
  - Iniciador de algún protocolo/algoritmo.
  - Ser el servidor para sincronizar relojes.
  - Acceder a un recurso crítico.
  - Entre otros.

Elección de líder - Características

- Cada proceso P_x debe tener un identificador único que puede ser directamente su PID, algún valor dinámico, alguna propiedad, una combinación de valores, etc.
- Cada proceso P_x tiene una variable $\texttt{elected}_x$ que contiene el identificador del proceso elegido como líder.

Elección de líder - Características

- Cada proceso P_x debe tener un identificador único que puede ser directamente su PID, algún valor dinámico, alguna propiedad, una combinación de valores, etc.
- Cada proceso P_x tiene una variable $\texttt{elected}_x$ que contiene el identificador del proceso elegido como líder.
- Se espera que todo algoritmo de elección de líder cumple con 2 propiedades:
  - ***Safery***: Un proceso P_x participante del algoritmo tiene $\texttt{elected}_x$ definido como "por definir" o como el ID del proceso que será el líder.
    - Nunca hay dos líderes válidos a la vez.
  - ***Liveness***: Todos los procesos P_x participan y, finalmente, establecen su variable $\texttt{elected}_x$ o fallan.
    - Siempre habrá un líder elegido eventualmente.

Algoritmos *Bully*

Elección de líder - Algoritmo *Bully*

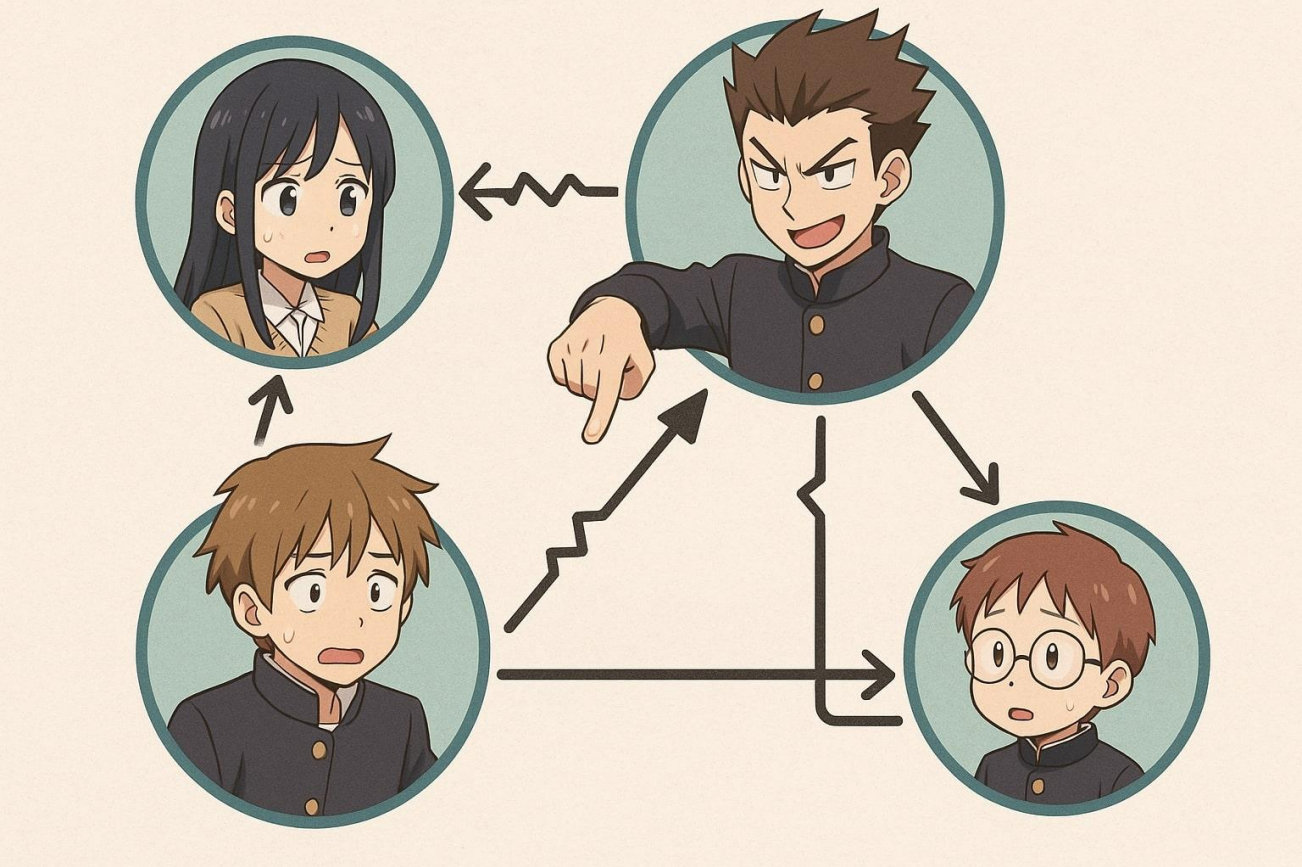

Fuente: OpenAI. (2025). [Representación Algoritmo *Bully*] [Imagen generada por inteligencia artificial con Sora]. https://openai.com/sora

Elección de líder - Algoritmo *Bully*

- Propuesto por Garcia-Molina en 1982.
- Es un algoritmo síncrono que utiliza tiempos de espera (*timeouts*) para detectar fallas en los nodos.
  - Se establece *delay* máximo de transmisión de mensajes (T_{trans})
  - Se establece *delay* máximo de procesamiento de mensajes ($T_{process}$)
  - Si un nodo demora más de $2 \times T_{trans} + T_{process}$ en responder, se asume una falla.
- Supuestos:
  - El identificador de cada nodo es un valor fijo que nunca cambia.
  - Cada nodo sabe qué nodo tienen identificadores más altos y puede comunicarse con todos ellos.

Elección de líder - Algoritmo *Bully* - Funcionamiento

- Este algoritmo utiliza tres tipos de mensajes:
  - **`Election`**: Anunciar una elección.
  - **`Ok`**: Respuesta a un mensaje `Election` para detener la candidatura.
  - **`Coordinator`**: Enviado para anunciar la identidad del proceso elegido.

Elección de líder - Algoritmo *Bully* - Funcionamiento

- **Caso inicial**: como todos saben el identificador de cada proceso. Aquel con mayor identificador manda mensaje Coordinator para avisar que será el líder

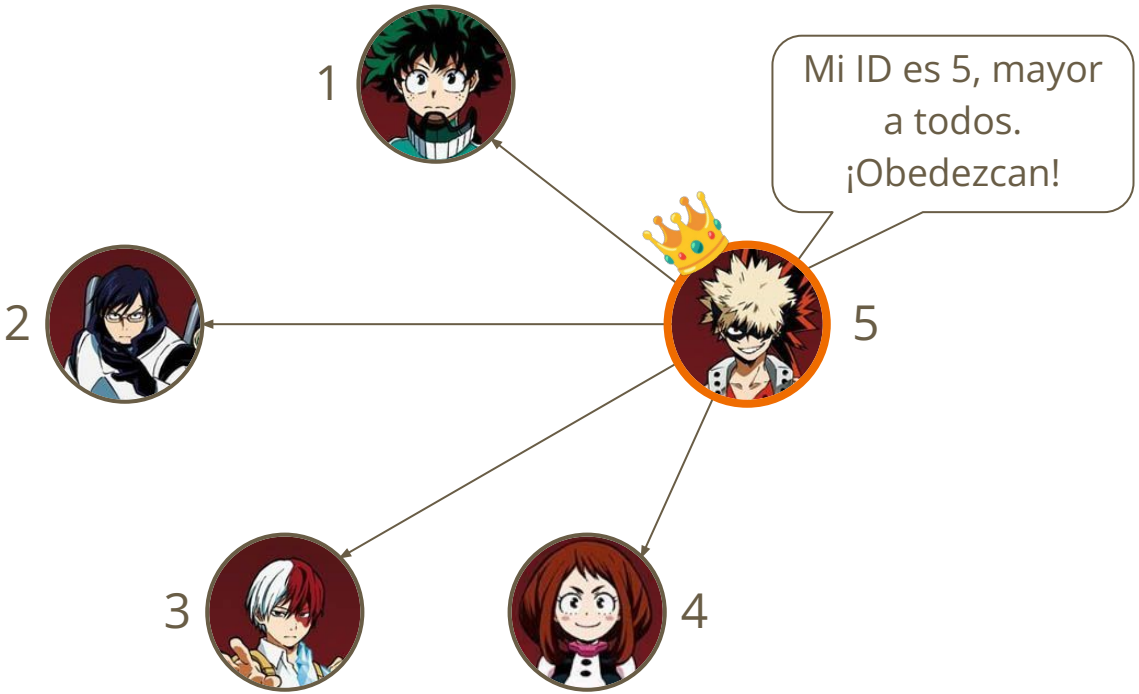

Elección de líder - Algoritmo *Bully* - Funcionamiento

- **Caso el líder falla/muere.** Algún nodo se da cuenta de esto y comienza elección.

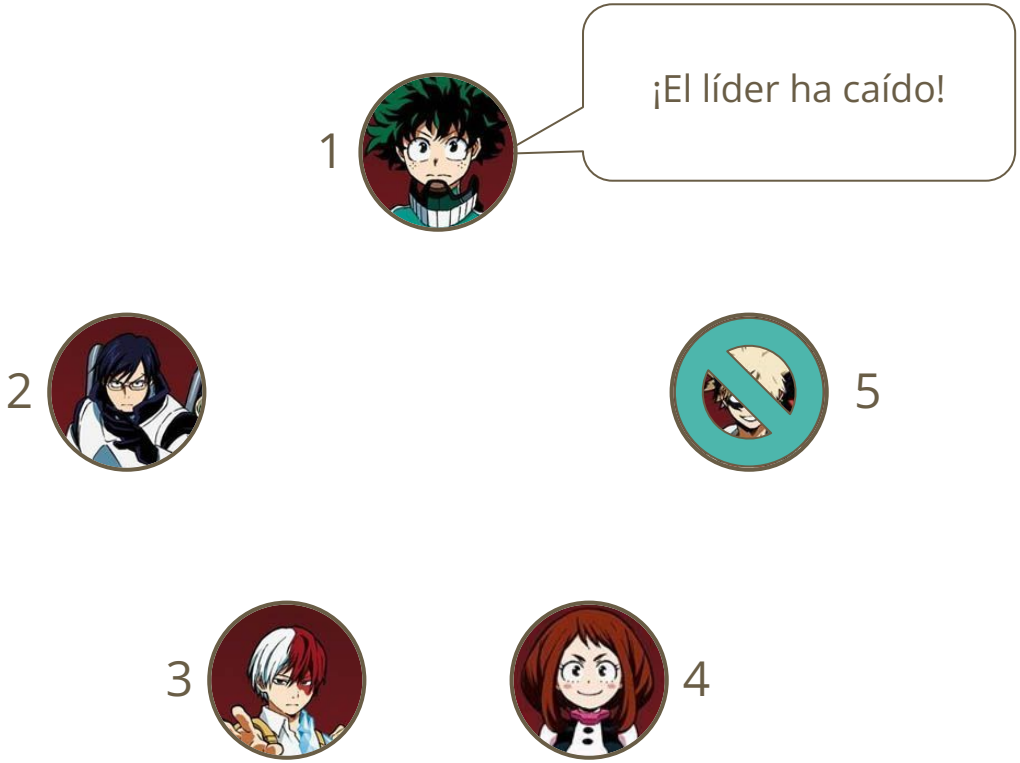

Elección de líder - Algoritmo *Bully* - Funcionamiento

- **Caso el líder falla/muere.** Algún nodo se da cuenta de esto y comienza elección.

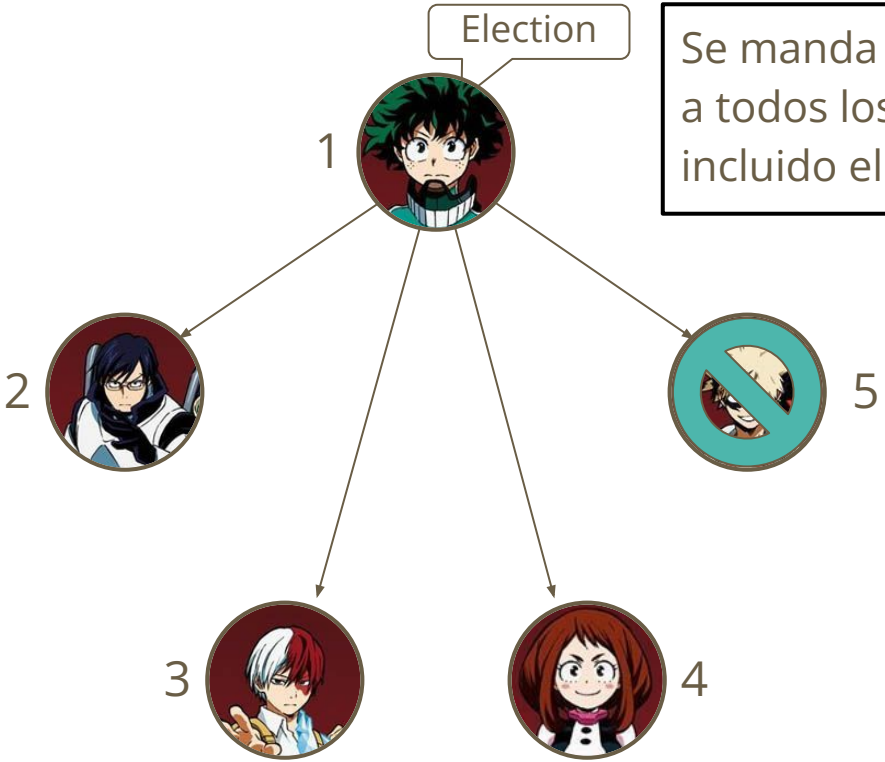

Se manda mensaje `Election` a todos los de ID superior incluido el caído.

Elección de líder - Algoritmo *Bully* - Funcionamiento

- **Caso el líder falla/muere.** Algún nodo se da cuenta de esto y comienza elección.

Los procesos responden "ok" al nodo menor, para que sepa que existe un nodo con mayor ID vivo.

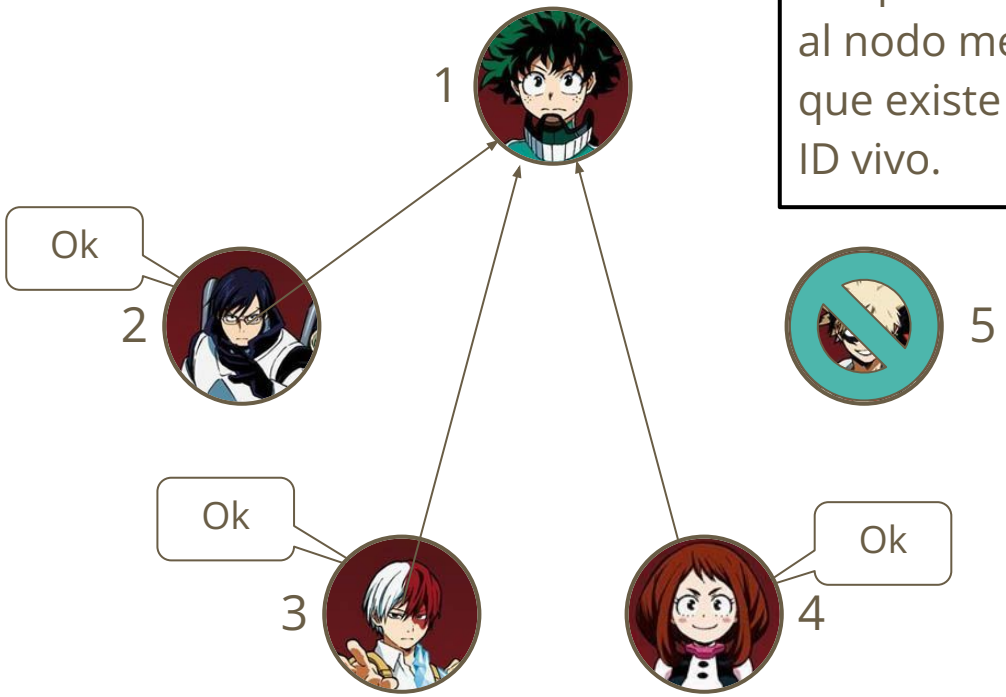

Elección de líder - Algoritmo *Bully* - Funcionamiento

- **Caso el líder falla/muere.** Algún nodo se da cuenta de esto y comienza elección.

Uno o más de los que respondió "ok" comienza la elección.

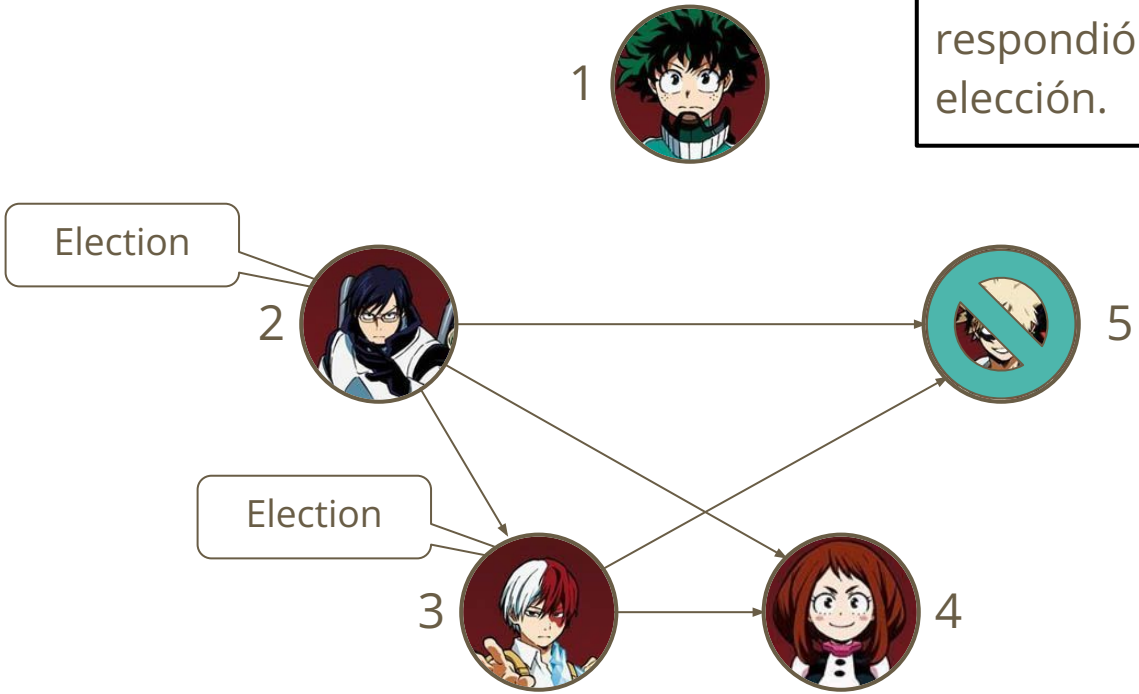

Elección de líder - Algoritmo *Bully* - Funcionamiento

- **Caso el líder falla/muere.** Algún nodo se da cuenta de esto y comienza elección.

El superior correspondiente responderá con "ok"

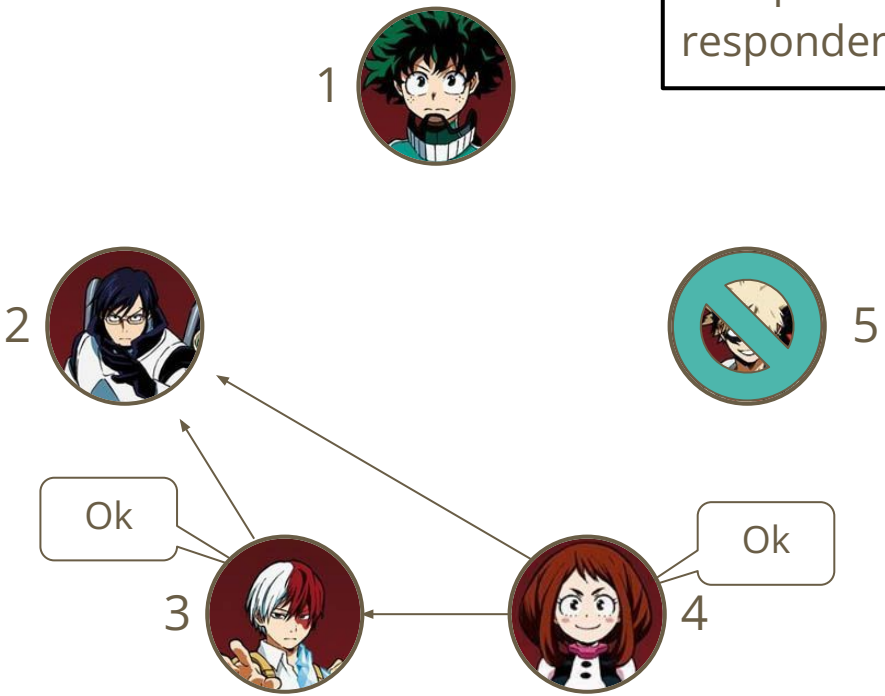

Elección de líder - Algoritmo *Bully* - Funcionamiento

- **Caso el líder falla/muere.** Algún nodo se da cuenta de esto y comienza elección.

Eventualmente el siguiente con mayor ID empezará la elección

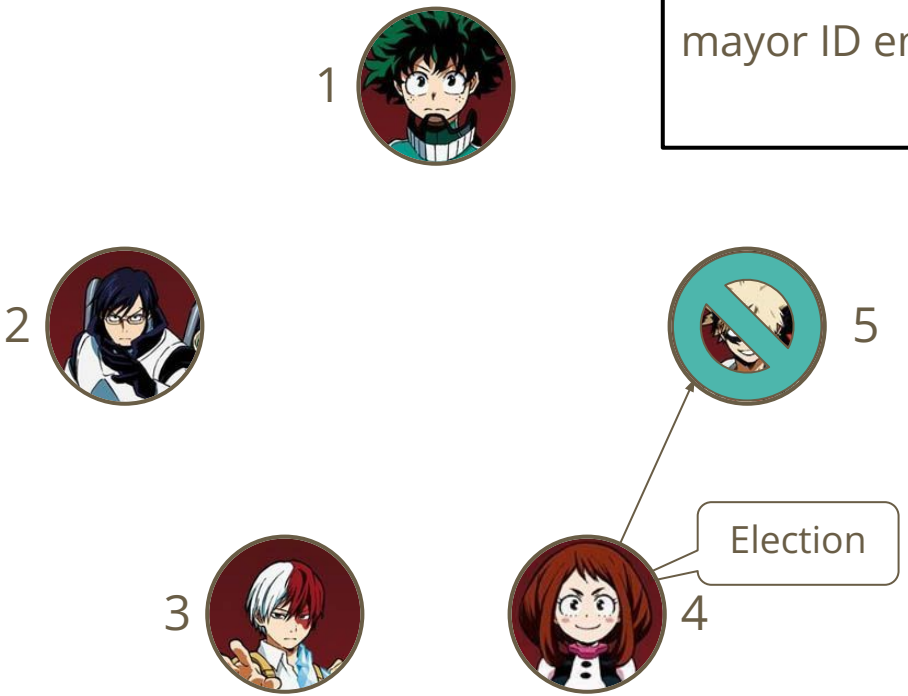

Elección de líder - Algoritmo *Bully* - Funcionamiento

- **Caso el líder falla/muere.** Algún nodo se da cuenta de esto y comienza elección.

No hay respuesta de nadie. Entonces, el nodo de ID 4 manda `Coordinator` a todos.

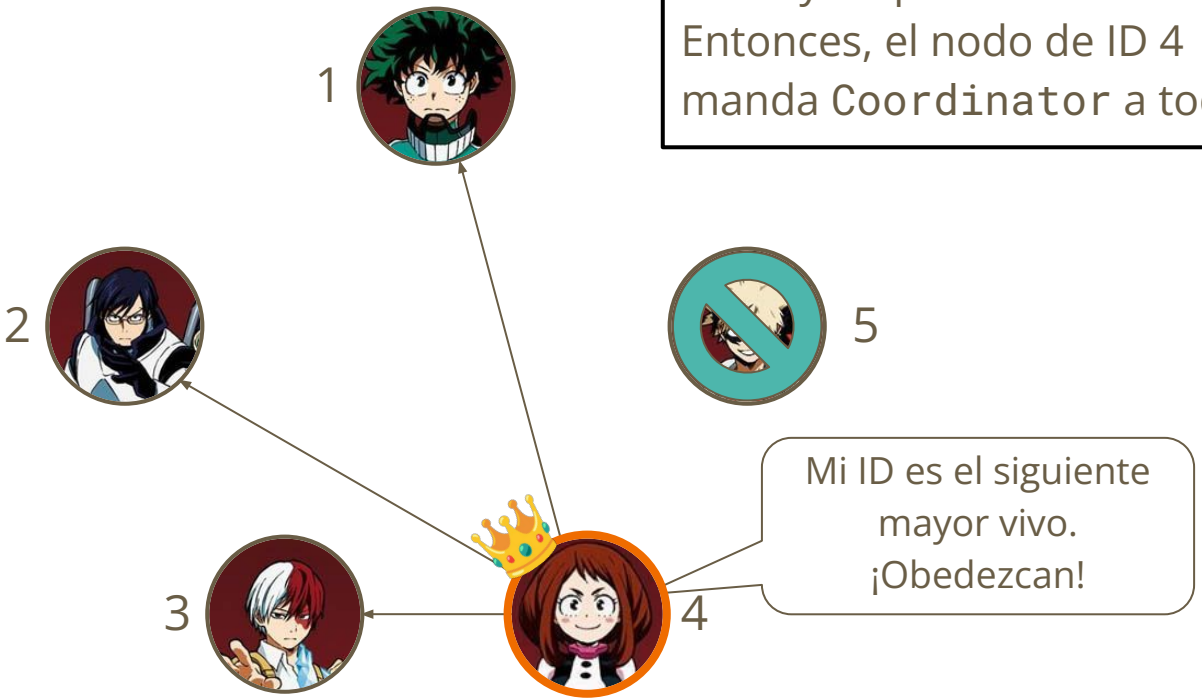

Elección de líder - Algoritmo *Bully* - Resumen

- Proceso con mayor identificador es líder siempre.
- Si líder se cae, algún proceso comienza la elección. Ese proceso contacta **exclusivamente** a todos con ID superior.
  - Si al menos uno con ID superior responde (Ok), entonces el candidato se retira de la elección. El proceso que respondió comienza la elección eventualmente.
  - Si ningún proceso con ID superior responde, entonces el que comenzó la elección está capacitado de ser líder y avisa a todos los procesos activos.

Elección de líder - Algoritmo *Bully* - Observaciones

- Es un algoritmo que, en el peor caso, se mandan demasiados mensajes.
  - El nodo con menor id manda `N-1` mensajes de `Election`.
  - El siguiente manda `N-2` mensajes de `Election`.
  - El siguiente manda `N-3` mensajes de `Election`.
  - Hasta llegar al segundo mejor proceso que manda 1 mensaje de `Election`.

Elección de líder - Algoritmo *Bully* - Observaciones

- Es un algoritmo que, en el peor caso, se mandan demasiados mensajes.
  - El nodo con menor id manda `N-1` mensajes de `Election`.
  - El siguiente manda `N-2` mensajes de `Election`.
  - El siguiente manda `N-3` mensajes de `Election`.
  - Hasta llegar al segundo mejor proceso que manda 1 mensaje de `Election`.
- En una red distribuida, no es garantía que siempre se sepa todos los nodos participantes y sus ID, por lo cual puede ser necesario enviar `Election` a muchos más nodos (incluso con ID menor) para tener mayor seguridad ser el con mayor ID.
  - Si un nodo con ID mayor envía `Election` a un nodo con ID menor, simplemente el con ID menor no responde.

Raft

Consenso de datos a través de la elección de un líder democráticamente

Raft - Introducción

- Propuesto el 2014 por Diego Ongaro y John Ousterhout.
- Trabajo original: In Search of an Understandable Consensus Algorithm
- Citando su paper:

  Raft is a consensus algorithm for managing a replicated log. It produces a result equivalent to (multi-)Paxos, and it is as efficient as Paxos, but its structure is different from Paxos; this makes Raft more understandable than Paxos...

Raft - Estados y fases

- Se proponen 3 estados:
  - **Seguidor (*Follower*)**: estado por defecto, solo responde a peticiones.
  - **Candidato (*candidate*)**: busca votos para ser el líder.
  - **Líder (*leader*)**: encargado de replicar las acciones para lograr consolidar.
- Hay 2 fases:
  - Elección de líder.
  - Replicación de *logs*.

Raft - Estados y fases

- Se proponen 3 estados:
  - **Seguidor (*Follower*)**: estado por defecto, solo responde a peticiones.
  - **Candidato (*candidate*)**: busca votos para ser el líder.
  - **Líder (*leader*)**: encargado de replicar las acciones para lograr consolidar.
- Hay 2 fases:
  - Elección de líder.
  - Replicación de *logs*.
- Hay un término que usaremos mucho: **"*term*"** que lo veremos como el "periodo de mandato" de un líder. Es un número que solo va creciendo.
- Todo nodo tiene un registro del *term* que lo compartirá con los demás nodos. El *term* más grande manda en todo momento.

Raft - Fase 1 - Elección de líder

- Cada nodo tiene un *election timeout* que es un número aleatorio entre 150 a 300 milisegundos. Es un intento de asegurar un número distinto por nodo.
- **Postulación:** cuando se acaba el *election timeout*, el nodo se postula como candidato.
  a. Aumenta el "*term*/mandato".
  b. El nodo vota por sí mismo.
  c. Le pide a todos los demás nodos que voten por él.
  d. Si logra mayoría, se vuelve líder.
  e. Si no logra mayoría, espera reiniciar su *election timeout* y vuelve a paso A.

Raft - Fase 1 - Elección de líder

- **Votación**: todo nodo que reciba solicitud de voto, debe responder:
  1. Si ya votó en el *term* actual o el *term* del candidato es menor al *term* del votante, **vota rechazo.**
  2. Si el nodo votante no tiene *logs* todavía, **vota a favor**.
  3. En otro caso, compara los *logs* (registro de acciones) del nodo votante y del candidato.
     a. Si el último *log* del candidato fue en un *term* mayor al nodo votante, **vota a favor del candidato.**
     b. Si el último *log* del candidato fue en un *term* igual al nodo votante, **solo se acepta si** su *log* es igual o más largo que el nodo votante.
     c. Si el último *log* del candidato fue en un *term* menos al nodo votante, **vota rechazo.**

Raft - Fase 1 - Elección de líder

Considerando la tupla (A_x, N) la acción X que se registró en el *log* durante el *term* N.

Caso 1 - [estado inicial]

[(A_1, 1), (A_2, 1), (A_3, 2)]
Term: 2
Timeout: 150

[(A_1, 1), (A_2, 1)]
Term: 2
Timeout: 200

[ ]
Term: 0
Timeout: 210

[(A_1, 1), (A_2, 1)]
Term: 1
Timeout: 250

Raft - Fase 1 - Elección de líder

Considerando la tupla (A_x, N) la acción X que se registró en el *log* durante el *term* N.

Caso 1 - El más actualizado comienza votación.

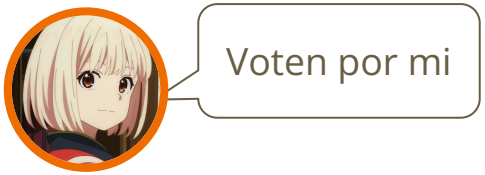

[(A_1, 1), (A_2, 1), (A_3, 2)]
Term: 3
Timeout: 150

[(A_1, 1), (A_2, 1)]
Term: 2
Timeout: 200

[ ]
Term: 0
Timeout: 210

[(A_1, 1), (A_2, 1)]
Term: 1
Timeout: 250

Raft - Fase 1 - Elección de líder

Considerando la tupla (A_x, N) la acción X que se registró en el *log* durante el *term* N.

Caso 1 - El más actualizado comienza votación.

Voten por mi

[(A_1, 1), (A_2, 1), (A_3, 2)]
Term: 3
Timeout: 150

Tu último registro está en *term 2* vs el mio que es *term* 1.
¡Voto por ti!

[(A_1, 1), (A_2, 1)]
Term: 2
Timeout: 200

No tengo *logs*
¡Voto por ti!

[ ]
Term: 0
Timeout: 210

Tu último registro está en *term 2* vs el mio que es *term* 1.
¡Voto por ti!

[(A_1, 1), (A_2, 1)]
Term: 1
Timeout: 250

Raft - Fase 1 - Elección de líder

Considerando la tupla (A_x, N) la acción X que se registró en el *log* durante el *term* N.

Caso 2 - El menos actualizado comienza votación.

[(A_1, 1), (A_2, 1), (A_3, 2)]
Term: 2
Timeout: 200

[(A_1, 1), (A_2, 1)]
Term: 2
Timeout: 210

[ ]
Term: 0
Timeout: 150

[(A_1, 1), (A_2, 1)]
Term: 2
Timeout: 250

Raft - Fase 1 - Elección de líder

Considerando la tupla (A_x, N) la acción X que se registró en el *log* durante el *term* N.

Caso 2 - El menos actualizado comienza votación.

[(A_1, 1), (A_2, 1), (A_3, 2)]
Term: 2
Timeout: 200

[(A_1, 1), (A_2, 1)]
Term: 2
Timeout: 210

Voten por mi

[ ]
Term: 1
Timeout: 150

[(A_1, 1), (A_2, 1)]
Term: 2
Timeout: 250

Raft - Fase 1 - Elección de líder

Considerando la tupla (A_x, N) la acción X que se registró en el *log* durante el *term* N.

Caso 2 - El menos actualizado comienza votación.

Tu *term* actual es menor al mío. **¡Rechazado!**

[(A_1, 1), (A_2, 1), (A_3, 2)]

Term: 2

Timeout: 200

Tu *term* actual es menor al mío. **¡Rechazado!**

[(A_1, 1), (A_2, 1)]

Term: 2

Timeout: 210

Voten por mi

[ ]

Term: 1

Timeout: 150

Tu *term* actual es menor al mío. **¡Rechazado!**

[(A_1, 1), (A_2, 1)]

Term: 2

Timeout: 250

Raft - Fase 1 - Elección de líder

Considerando la tupla (A_x, N) la acción X que se registró en el *log* durante el *term* N.

Caso 3 - *Log* no tan actualizado

[(A_1, 1), (A_2, 1), (A_3, 2)]
Term: 2
Timeout: 220

[(A_1, 1), (A_2, 1)]
Term: 2
Timeout: 150

[ ]
Term: 0
Timeout: 210

[(A_1, 1), (A_2, 1)]
Term: 2
Timeout: 250

Raft - Fase 1 - Elección de líder

Considerando la tupla (A_x, N) la acción X que se registró en el *log* durante el *term* N.

Caso 3 - *Log* no tan actualizado

[(A_1, 1), (A_2, 1), (A_3, 2)]
Term: 2
Timeout: 220

[(A_1, 1), (A_2, 1)]
Term: 3
Timeout: 150

[ ]
Term: 0
Timeout: 210

[(A_1, 1), (A_2, 1)]
Term: 2
Timeout: 250

Raft - Fase 1 - Elección de líder

Considerando la tupla (A_x, N) la acción X que se registró en el *log* durante el *term* N.

Caso 3 - *Log* no tan actualizado

Tu último *log tiene un term* menor al mío.
¡Rechazado!

[(A_1, 1), (A_2, 1), (A_3, 2)]
Term: 2
Timeout: 220

Voten por mi

[(A_1, 1), (A_2, 1)]
Term: 3
Timeout: 150

No tengo *logs*
¡Voto por ti!

[ ]
Term: 0
Timeout: 210

Nuestro último log es igual en *term*. El largo es el mismo.
¡Voto por ti!

[(A_1, 1), (A_2, 1)]
Term: 2
Timeout: 250

Raft - Fase 1 - Elección de líder (Resumen)

- Todos parten como *seguidores* y votan una vez por *term*/mandato.
- **Postulación:** se acaba el *election timeout* de un nodo y se convierte en candidato.
- **Votación**: solo se rechaza si el nodo candidato está menos actualizado que el nodo votante. En caso de empate, se acepta al nodo candidato.
- **Elección de líder**: el candidato logra tener mayoría de votos.

Raft - Fase 1 - Elección de líder (Peeero)

Siendo el líder...

> 🤔 *¿Cómo evito perder el trono, es decir, cómo evito que empiece otra votación?* 🤔

Heartbeat: el líder manda constantemente un mensaje a todos los seguidores para reiniciar su *election timeout.*

Raft - Fase 1 - Elección de líder (Peeero)

Siendo el líder...

🤔 *¿Cómo evito perder el trono, es decir, cómo evito que empiece otra votación?* 🤔

Heartbeat: el líder manda constantemente un mensaje a todos los seguidores para reiniciar su *election timeout.*

🤔 *Y si me desconecto y vuelvo... ¿cómo me doy cuenta que empezó una votación ?* 🤔

Cuando se comienza una votación, el *term* aumenta. Cualquier nodo que ve un *term* mayor al suyo se vuelve seguidor de inmediato y actualiza su *term* al valor más grande recibido.

Raft - Fase 2 - Replicación de *logs*

Logs

- Lista de tuplas. Cada tupla tiene la operación y el *term* en que se creó la operación.

Replicación

- El líder recibe operaciones, la guarda en su *log*.
- Si un seguidor recibe una operación, la redirige al líder.
- Líder intenta replicar su *log* en seguidores.
- Si una posición del *log* tiene conflicto entre la tupla del líder y del seguidor, gana la tupla del líder.

Raft - Fase 2 - Replicación de *logs*

Replicar

- Líder intenta replicar su *log* en seguidores.
- Si una posición del *log* tiene conflicto entre la tupla del líder y del seguidor, gana la tupla del líder.

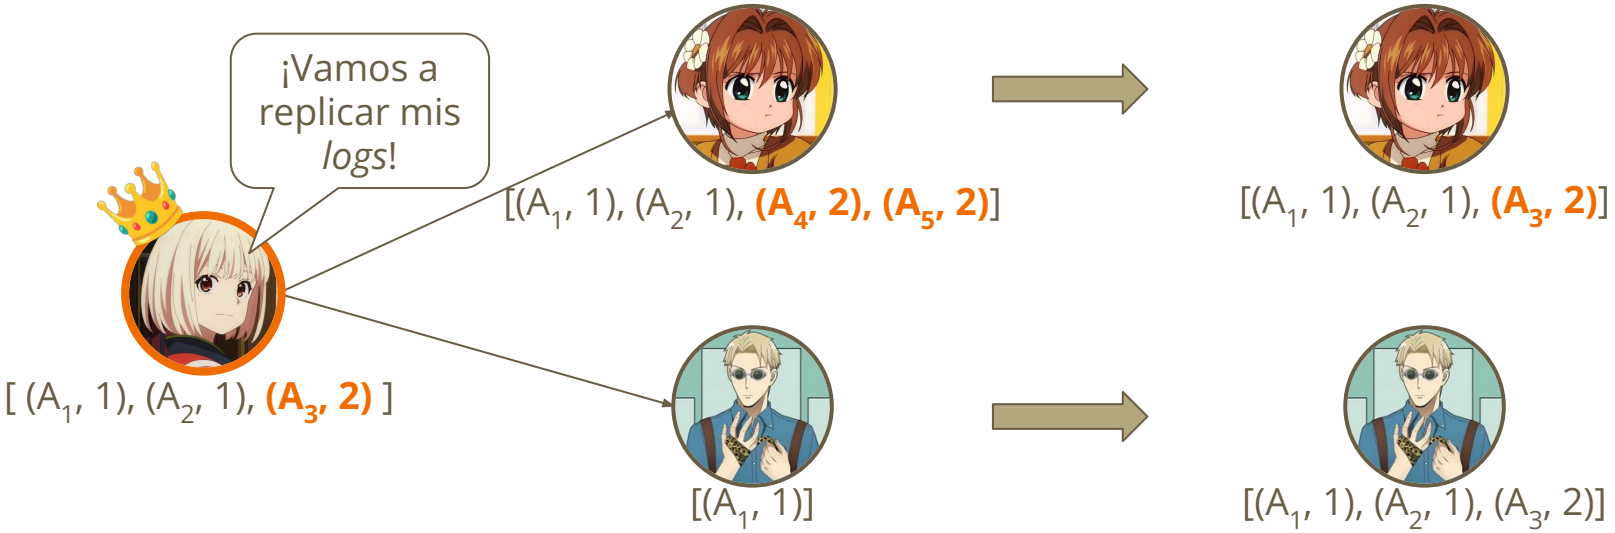

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Term 1

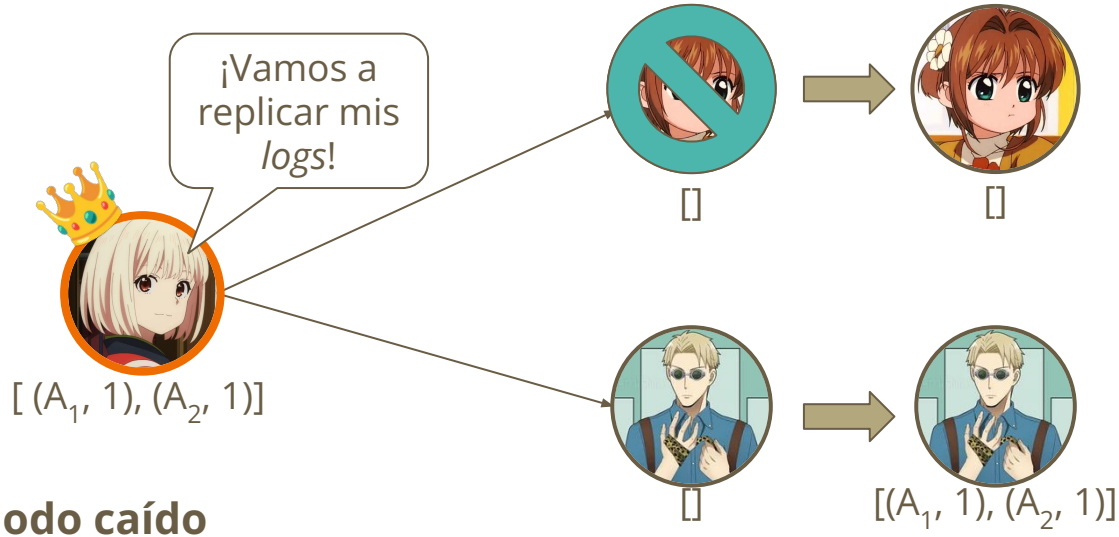

Las acciones A_1 y A_2 serán consolidadas.

Las tiene el líder y un seguidor (2 de nodos de 3),

Nodo caído

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Term	1
A-1	
B-5	
C-4	
D-3	
E-2	

Cada nodo tiene un ID (la letra) y un *election timeout* distinto (el número después de la letra)

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Term	1
A-1	$(A_1,1)$
B-5	
C-4	
D-3	
E-2	

A es líder por menor *timeout*
y le llega una acción.

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Replica su *log* a B

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Nodo caído

Term	1	2
A-1	$(A_1,1)$	$(A_1,1)$
B-5	$(A_1,1)$	$(A_1,1)$
C-4		
D-3		
E-2		

A se cae temporalmente. E, segundo con menor *timeout*, logra mayoría gracias al voto de C y E.

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Nodo caído

Term	1	2
A-1	$(A_1,1)$	$(A_1,1)$
B-5	$(A_1,1)$	$(A_1,1)$
C-4		
D-3		
E-2		$(A_2,2)$

Llega acción a E.

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Nodo caído

Term	1	2	3
A-1	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
B-5	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
C-4			
D-3			
E-2		$(A_2,2)$	$(A_2,2)$

E se cae temporalmente.
A recupera liderazgo por menor *timeout* y su último log es más actualizado que C y D.

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Term	1	2	3
A-1	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
B-5	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
C-4			$(A_1,1)$
D-3			
E-2		$(A_2,2)$	$(A_2,2)$

A replica su *log* a C.

¿A_1 se considera consolidado?

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Term	1	2	3
A-1	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
B-5	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
C-4			$(A_1,1)$
D-3			
E-2		$(A_2,2)$	$(A_2,2)$

¿A_1 se considera consolidado?

No, estamos en *term* 3, y esta acción fue creada en *term 1*.

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Term	1	2	3
A-1	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
B-5	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
C-4			$(A_1,1)$
D-3			
E-2		$(A_2,2)$	$(A_2,2)$

¿A_1 se considera consolidado?

No, estamos en *term* 3, y esta acción fue creada en *term 1*.

Incluso... puede pasar lo siguiente

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Term	1	2	3	4
A-1	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
B-5	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
C-4			$(A_1,1)$	$(A_1,1)$
D-3				
E-2		$(A_2,2)$	$(A_2,2)$	$(A_2,2)$

Nodo caído

A se cae por un buen tiempo.
E se vuelve líder porque tiene menor *timeout* y su último *log* tiene el *term* más actual.

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Nodo caído

Term	1	2	3	4
A-1	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
B-5	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$	$(A_2,2)$
C-4			$(A_1,1)$	$(A_2,2)$
D-3				$(A_2,2)$
E-2		$(A_2,2)$	$(A_2,2)$	$(A_2,2)$

E replica su *logs* a todos los nodos activos

Ahora A_1 ni siquiera está en la mayoría.

Pero A_2 ahora sí está en mayoría, debería ser consolidado...

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Term	1	2	3	4
A-1	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
B-5	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$	$(A_2,2)$
C-4			$(A_1,1)$	$(A_2,2)$
D-3				$(A_2,2)$
E-2		$(A_2,2)$	$(A_2,2)$	$(A_2,2)$

Nodo caído

E replica su *logs* a todos los nodos activos

Ahora A_1 ni siquiera está en la mayoría.

Pero A_2 ahora sí está en mayoría, debería ser consolidado... No

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Nodo caído

Term	1	2	3
A-1	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
B-5	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
C-4			
D-3			
E-2		$(A_2,2)$	$(A_2,2)$

Volvamos a esta situación

E se cae temporalmente.
A recupera liderazgo por menor *timeout* y su último log es más actualizado que C y D.

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Nodo caído

Llega una acción a A.

Term	1	2	3
A-1	$(A_1,1)$	$(A_1,1)$	$(A_1,1)(A_3, 3)$
B-5	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
C-4			$(A_1,1)$
D-3			
E-2		$(A_2,2)$	$(A_2,2)$

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Term	1	2	3	4
A-1	$(A_1,1)$	$(A_1,1)$	$(A_1,1)(A_3, 3)$	$(A_1,1)(A_3, 3)$
B-5	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
C-4			$(A_1,1)$	$(A_1,1)$
D-3				
E-2		$(A_2,2)$	$(A_2,2)$	$(A_2,2)$

Nodo caído

A se cae por un buen tiempo.

E se vuelve líder porque tiene menor *timeout* y su último *log* tiene el *term* más actual.

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Nodo caído

E replica su *logs* a todos los nodos activos.

Term	1	2	3	4
A-1	$(A_1,1)$	$(A_1,1)$	$(A_1,1)(A_3,3)$	$(A_1,1)(A_3,3)$
B-5	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$	$(A_2,2)$
C-4			$(A_1,1)$	$(A_2,2)$
D-3				$(A_2,2)$
E-2		$(A_2,2)$	$(A_2,2)$	$(A_2,2)$

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Term	1	2	3	4
A-1	$(A_1,1)$	$(A_1,1)$	$(A_1,1)(A_3, 3)$	$(A_1,1)(A_3, 3)$
B-5	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$	$(A_2,2)$
C-4			$(A_1,1)$	$(A_2,2)$
D-3				$(A_2,2)$
E-2		$(A_2,2)$	$(A_2,2)$	$(A_2,2)$

Nodo caído

Si A vuelve y E se cae

El último *log* de A tiene un *term* mayor a todos.
A es líder y puede hacer que A_2 se sobreescriba.

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada.**

Raft - Fase 2 - Replicación de *logs*

Consolidación (directa)

- Una acción/operación es consolidada solo si esta fue replicada **a la mayoría de los nodos en el mismo mandato que fue creada**.

Consolidación (indirecta)

- Una acción/operación es consolidada indirectamente si existe una operación del *log* que fue consolidada **directamente**.

Raft - Fase 2 - Replicación de *logs*

Consolidación (indirecta)

- Una acción/operación es consolidada indirectamente si existe una operación del *log* fue consolidada **directamente.**

Term	1	2	3
A-1	$(A_1,1)$	$(A_1,1)$	$(A_1,1)(A_3, 3)$
B-5	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
C-4			$(A_1,1)$
D-3			
E-2		$(A_2,2)$	$(A_2,2)$

Volvamos a esta situación del ejemplo anterior.

Raft - Fase 2 - Replicación de *logs*

Consolidación (indirecta)

- Una acción/operación es consolidada indirectamente si existe una operación del *log* fue consolidada **directamente.**

Term	1	2	3
A-1	$(A_1,1)$	$(A_1,1)$	$(A_1,1)(A_3, 3)$
B-5	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
C-4			$(A_1,1)$
D-3			
E-2		$(A_2,2)$	$(A_2,2)$

Volvamos a esta situación del ejemplo anterior.

A va a replicar su *logs a C y D.*

Raft - Fase 2 - Replicación de *logs*

Consolidación (indirecta)

- Una acción/operación es consolidada indirectamente si existe una operación del *log* fue consolidada **directamente.**

Term	1	2	3
A-1	$(A_1,1)$	$(A_1,1)$	$(A_1,1)(A_3,3)$
B-5	$(A_1,1)$	$(A_1,1)$	$(A_1,1)$
C-4			$(A_1,1)(A_3,3)$
D-3			$(A_1,1)(A_3,3)$
E-2		$(A_2,2)$	$(A_2,2)$

A_3 fue consolidada directamente. Por lo tanto, A_1 fue consolidada indirectamente.

Mientras exista mayoría de nodos (requisito del algoritmo), el líder será A, C o D que tienen A_1 y A_3.

Raft - Garantías (las mismas que Paxos)

- **Tolerancia a fallos**

  Pueden fallar `(N-1)//2` nodos.

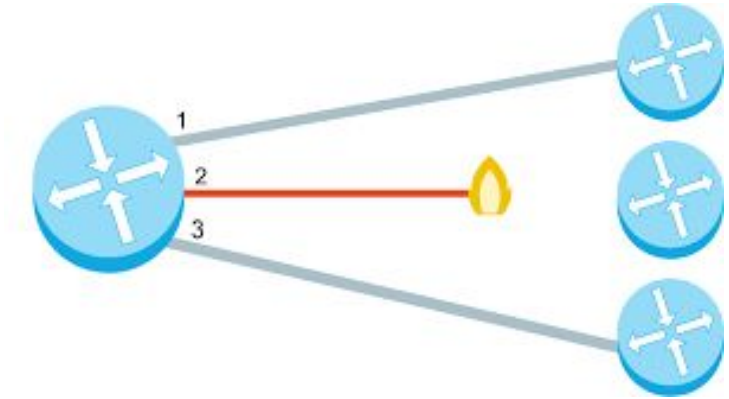

- **Tolerancia a particiones.**

  Si se divide la red en 2 grupos, mientras uno tenga la mayoría, el algoritmo funciona.

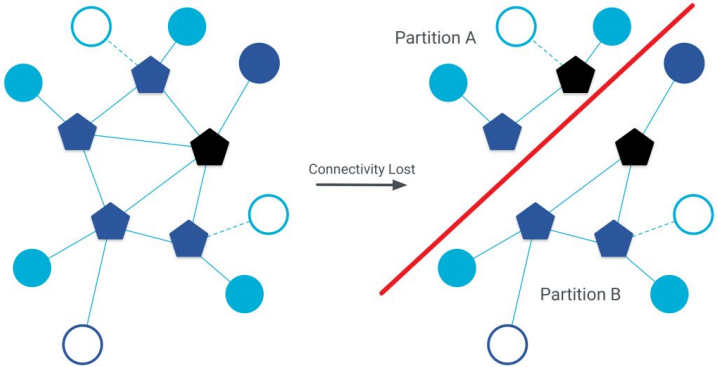

Raft - Vida real

- **etcd** (base de datos clave-valor) utiliza Raft para gestionar su log replicado; es la base de Kubernetes, Docker Swarm, entre otros.
- **Neo4j** (base de datos de grafos) garantiza consistencia y seguridad mediante Raft. eBay ocupa Neo4j.
- **ScyllaDB** (base de datos distribuida NoSQL) usa Raft internamente para metadata y transacciones. Discord y Disney+ ocupan ScyllaDB.

Ring-based Election

Solo lo vemos si nos da el tiempo, sino lo estudiaremos con calma el miércoles 8 de abril.

Elección de líder - Algoritmo *Ring-based*

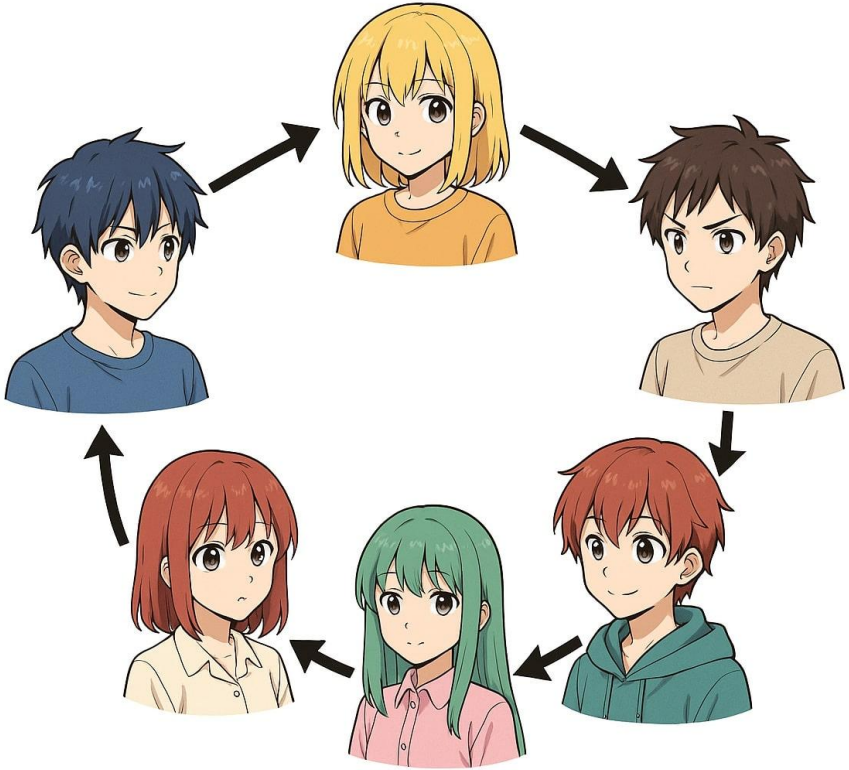

Fuente: OpenAI. (2025). [Representación Algoritmo *Ring-based*] [Imagen generada por inteligencia artificial con Sora]. https://openai.com/sora

Elección de líder - Algoritmo *Ring-based*

- Propuesto por Chang y Roberts en 1979.
- Los procesos están organizados en forma de un anillo y cada proceso conoce solo el vecino más cercano, no toda la red.
  - Cada proceso P_i tiene un comunicación al siguiente proceso en el anillo, $P_{i+1} \ mod \ N$
- Es un algoritmo asíncrono y, por defecto, no es tolerante a fallos.
- Supuestos:
  - El identificador de cada proceso es un valor fijo que nunca cambia.
  - Cada proceso NO sabe el identificador de los demás procesos.

Elección de líder - Algoritmo *Ring-based* - Funcionamiento

- Este algoritmo, por defecto, utiliza 2 tipos de mensajes:
  - **`Election`**: Anunciar una elección.
  - **`Elected`**: Enviado para anunciar la identidad del proceso elegido.

Elección de líder - Algoritmo *Ring-based* - Funcionamiento

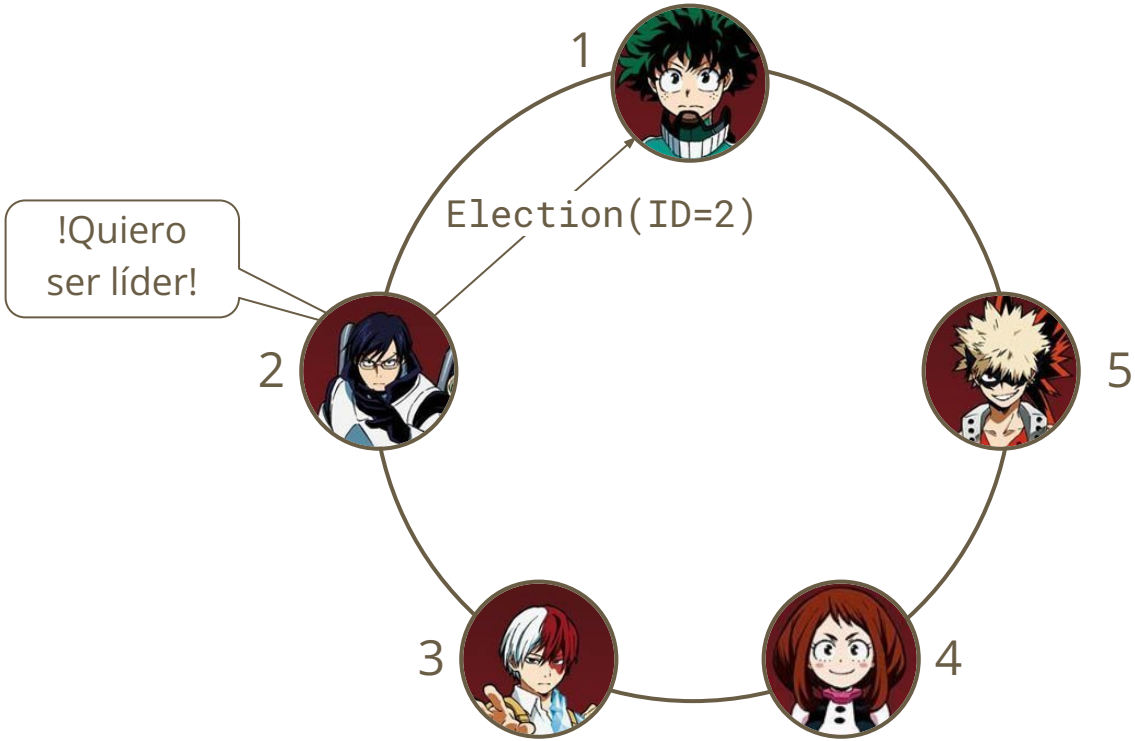

Elección de líder - Algoritmo *Ring-based* - Funcionamiento

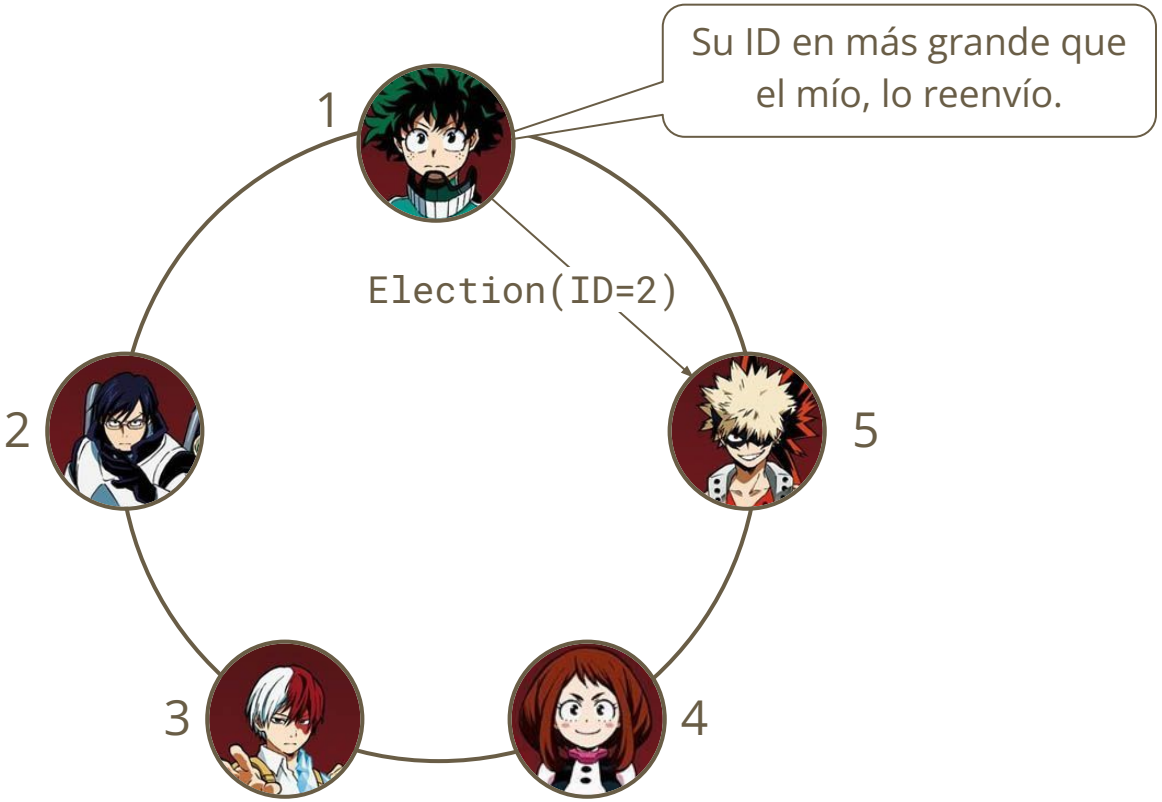

Elección de líder - Algoritmo *Ring-based* - Funcionamiento

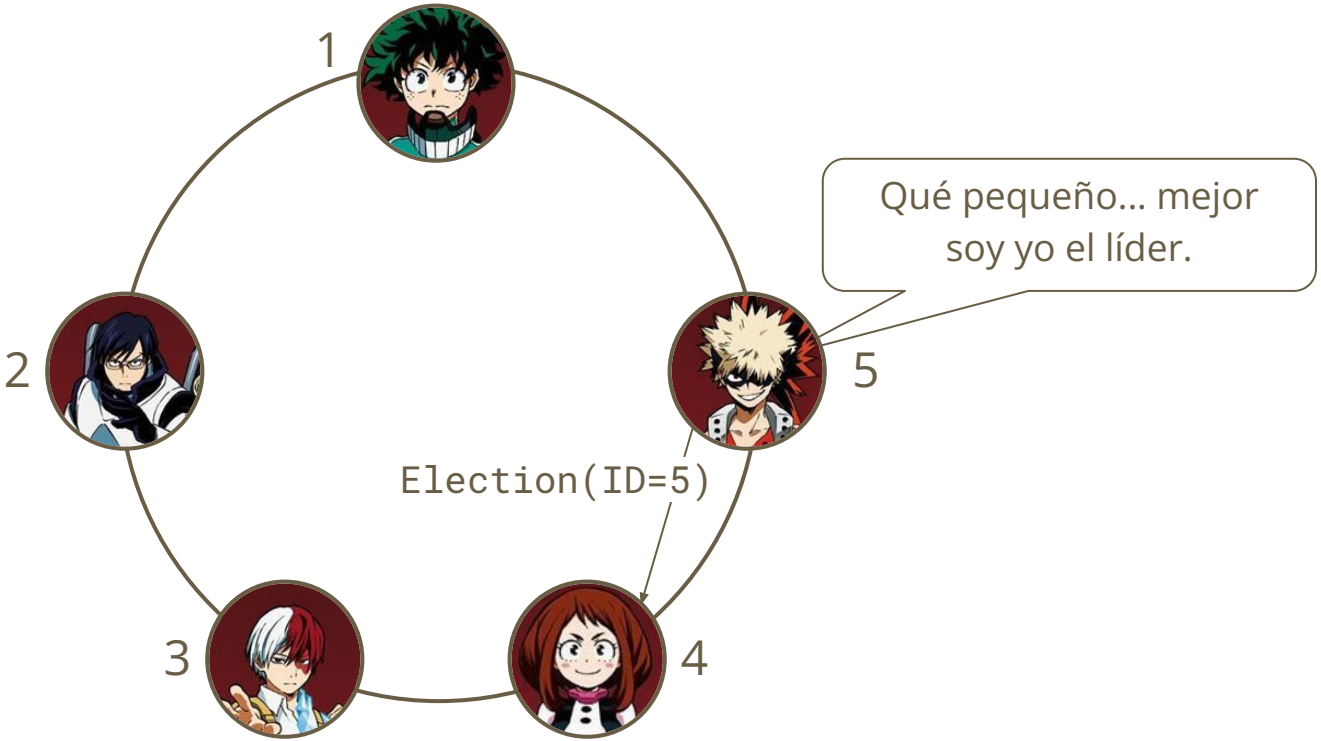

Elección de líder - Algoritmo *Ring-based* - Funcionamiento

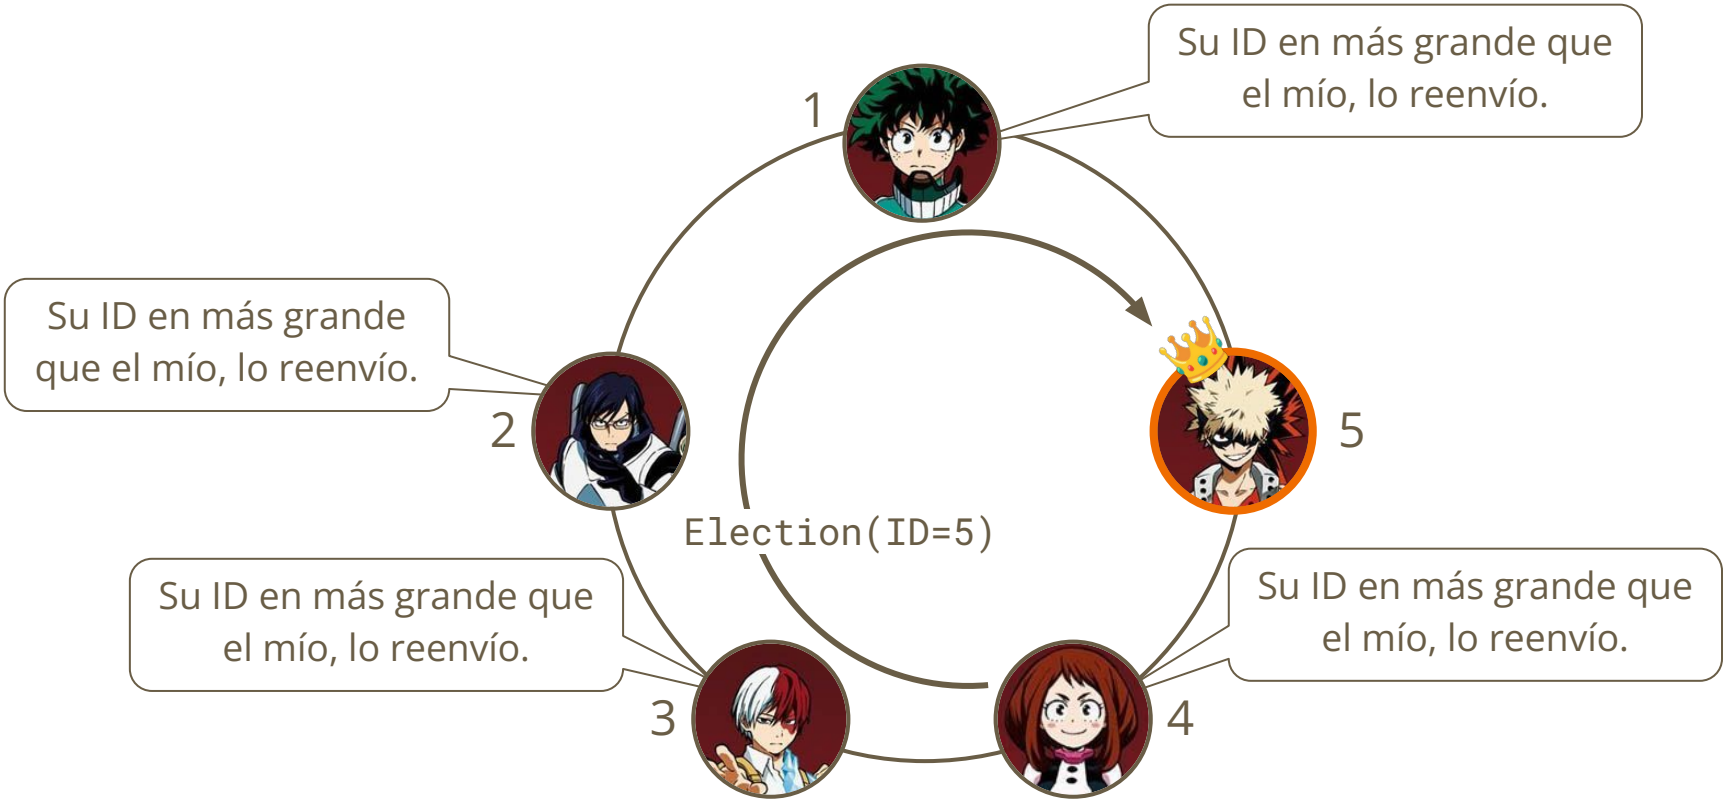

Elección de líder - Algoritmo *Ring-based* - Funcionamiento

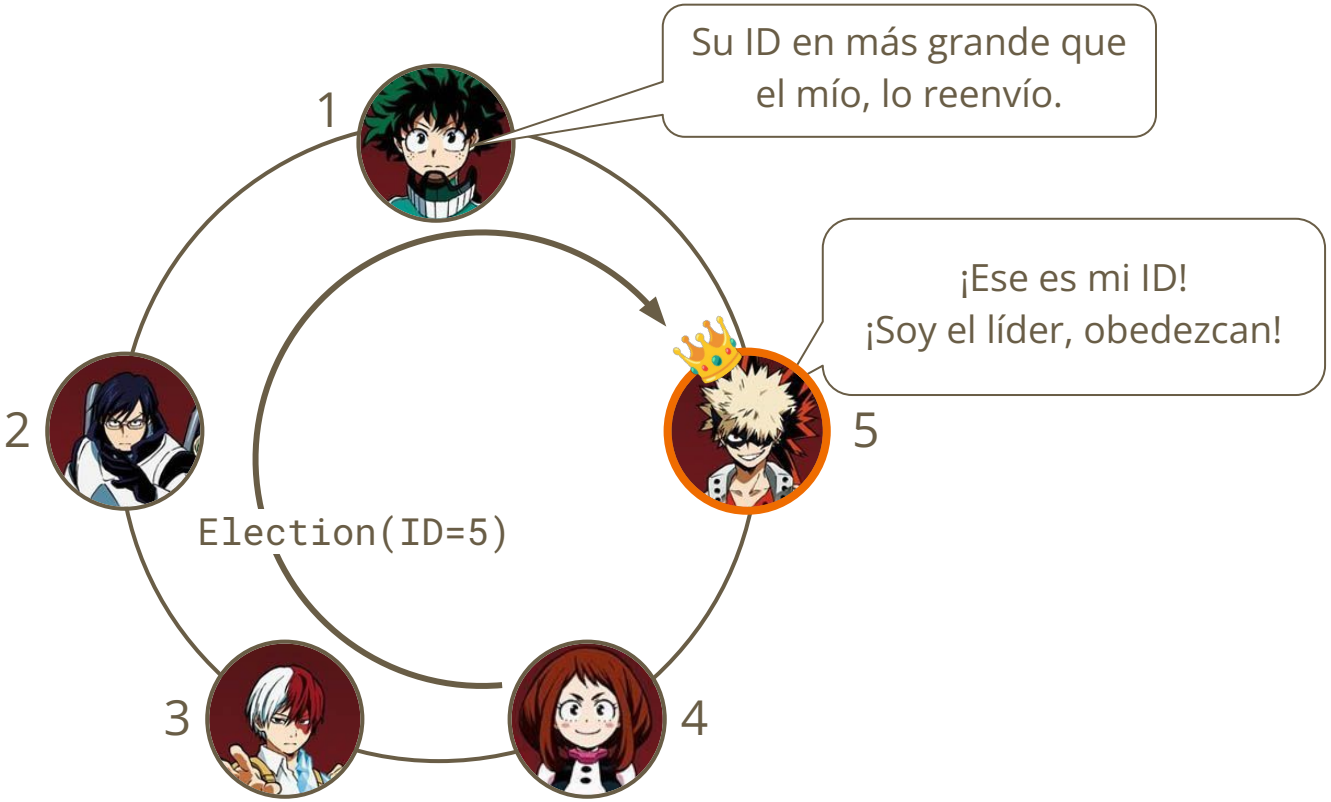

Elección de líder - Algoritmo *Ring-based* - Funcionamiento

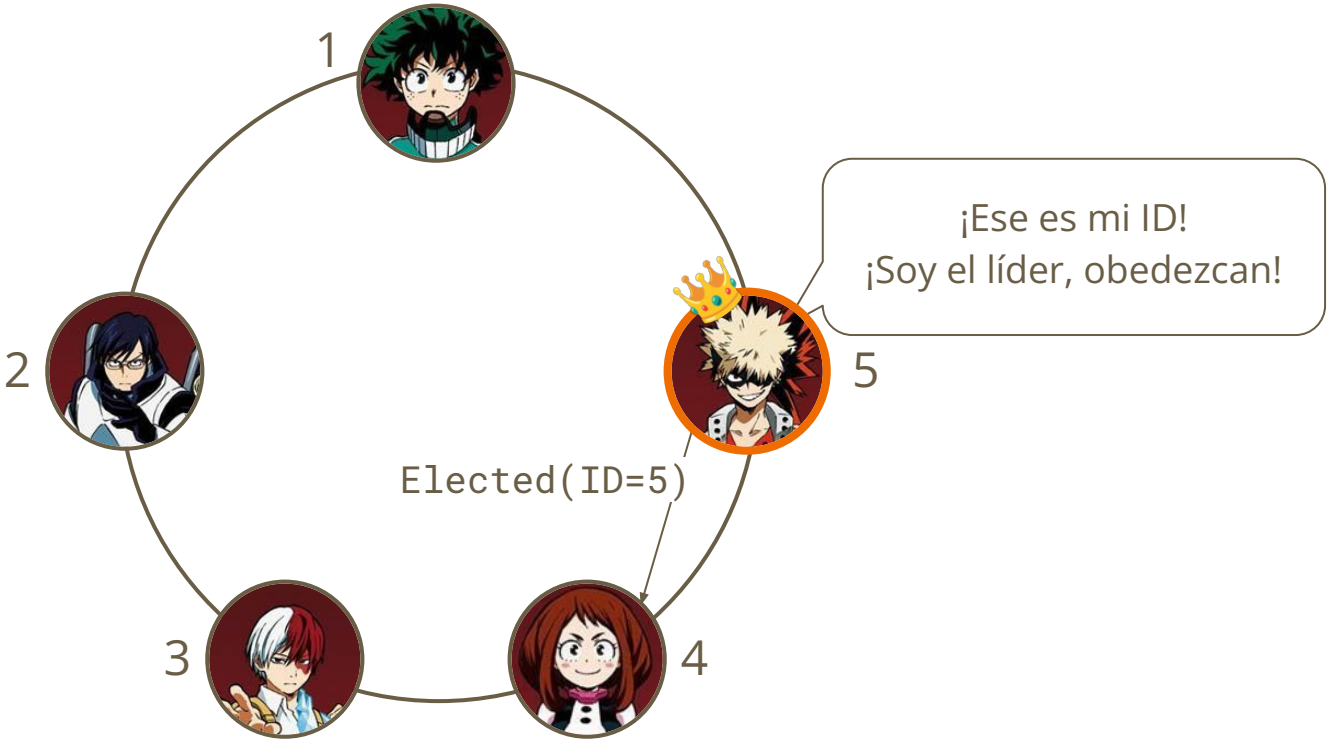

Elección de líder - Algoritmo *Ring-based* - Funcionamiento

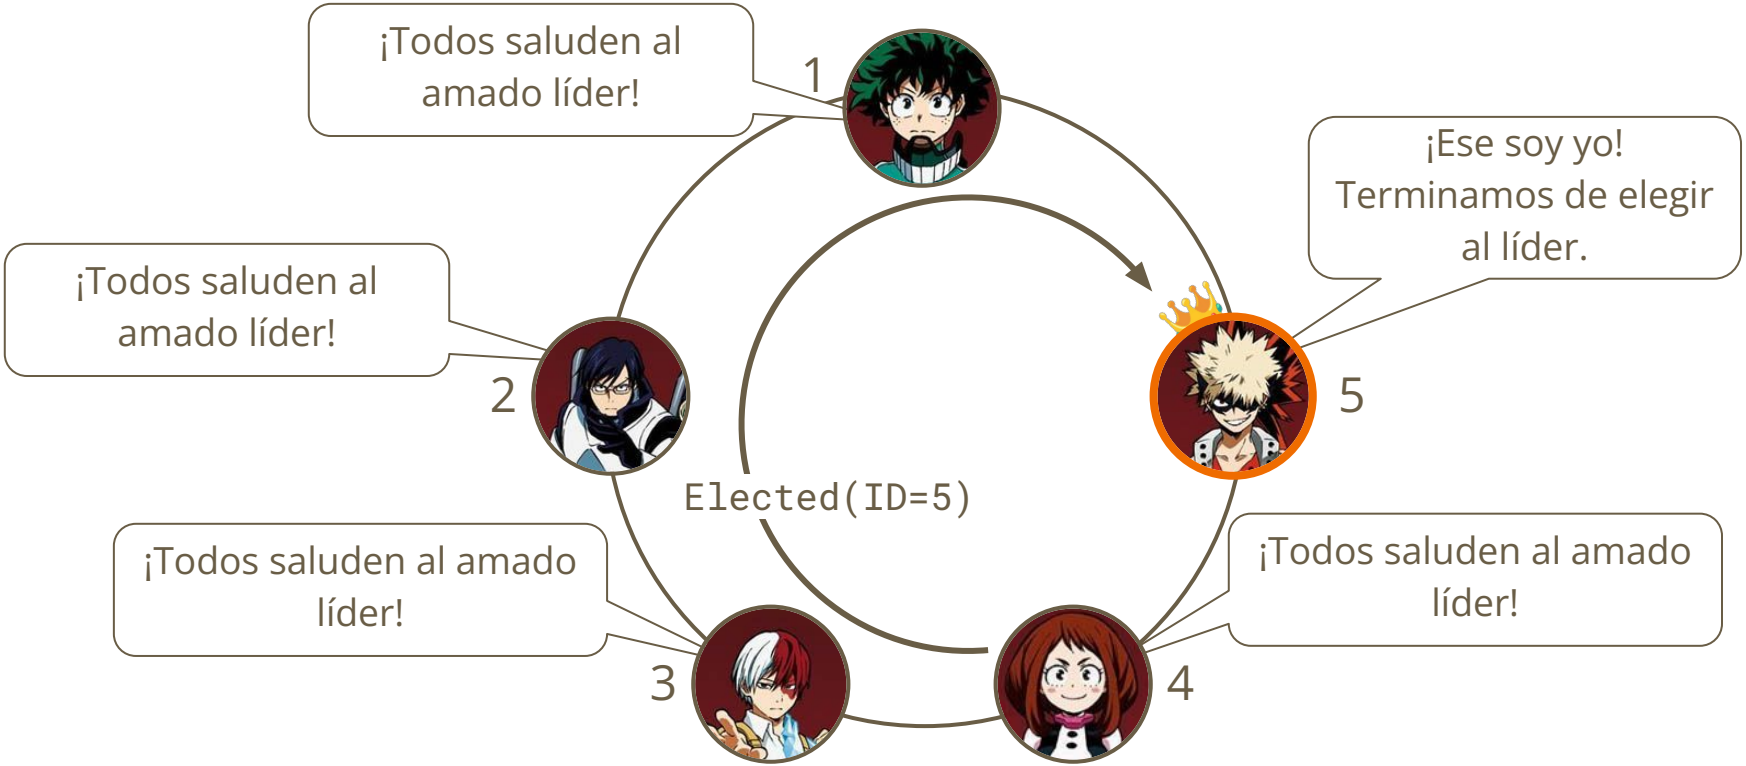

Elección de líder - Algoritmo *Ring-based* - Resumen

- Cualquier proceso P_i se auto elige como líder, y manda un mensaje de `Election` a su vecino adjuntando su propio $\texttt{ID}_i$.
- Cuando proceso P_x recibe mensaje tipo `Election` con ID_i
  - Si $ID_i < ID_x$ se reemplaza ID_i por ID_x y se manda el mensaje `Election` con ID_x
  - Si $ID_i > ID_x$ se reenvía el mensaje al siguiente vecino sin cambiar nada.
  - Si $ID_i == ID_x$ significa que el mensaje dió una vuelta completa. Se comienza a notificar que el líder será el proceso con ID_i, y se espera que el mensaje de una vuelta completa.

Elección de líder - Algoritmo *Ring-based* - Observaciones

- En el peor caso que el proceso con mayor ID es justo el anterior al proceso que comienza la elección, se mandarán `3 x N - 1` mensajes.
- Existen muchas variaciones a este tipo de algoritmo:
  - Comunicación bi-direccional.
  - Agregar *timeouts* para transformarlo en un algoritmo síncrono.
  - Conocer al "vecino del vecino" para poder saltar a algún nodo en caso de caídas.
  - Agregar mensajes de respuestas al `Election`.

Poniendo a prueba lo que hemos aprendido 👀

Respecto a la consolidación de datos utilizando el algoritmo Raft visto en clases, ¿cuál de las siguientes afirmaciones es **incorrecta**?

I. Una operación que no fue consolidado durante un *term* nunca podrá consolidarse en mandatos posteriores.

II. Si una operación logra almacenarse en la mayoría de los nodos luego de diferentes mandatos, se garantiza que dicha operación será consolidado.

III. Si una operación se almacena en la mayoría de los nodos durante el mismo *term* este será consolidado.

IV. Es posible consolidar más de una operación en un mismo *term*.

a. Solo I
b. Solo II
c. I y II
d. III y IV
e. I, II y III

Poniendo a prueba lo que hemos aprendido 👀

Respecto a la consolidación de datos utilizando el algoritmo Raft visto en clases, ¿cuál de las siguientes afirmaciones es **incorrecta**?

I. Una operación que no fue consolidado durante un *term* nunca podrá consolidarse en mandatos posteriores.

II. Si una operación logra almacenarse en la mayoría de los nodos luego de diferentes mandatos, se garantiza que dicha operación será consolidado.

III. Si una operación se almacena en la mayoría de los nodos durante el mismo *term* este será consolidado.

IV. Es posible consolidar más de una operación en un mismo *term*.

a. Solo I
b. Solo II
c. I y II
d. III y IV
e. I, II y III

Próximos eventos

Próxima clase

- Profundizaremos en algoritmos de exclusión mutua
  - ¿Cómo aseguramos que 1 nodo acceda a una zona crítica ahora que están repartidos y hay latencia en la comunicación?

Evaluación

- Mañana (martes) se finaliza plazo máximo (con atraso) de la T1.
- Actividad **obligatoria**: control de 2 preguntas sobre la clase de hoy.

IIC2523
Sistemas Distribuidos

Hernán F. Valdivieso López
(2026 - 1 / Clase 08)

Créditos (animes utilizados)

Lycoris Recoil

Oshi no Ko

Sakura Card Captor

One Piece

Sword Art Online

Boku no Hero Academia

Shingeki no Kyojin

Konosuba

Spy x Family